

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I



BÁO CÁO HÀNG TUẦN
HỌC PHẦN: THỰC TẬP CƠ SỞ
ĐỀ TÀI

Giảng viên hướng dẫn	: TS. Kim Ngọc Bach
Mã sinh viên	: B23DCCN397
Tên sinh viên	: Nguyễn Nhật Huy
Lớp hành chính	: D23CQCN05-B
Nhóm thực tập	: 11

Hà Nội – 2026

I. Đề xuất cải tiến mô hình SalsaNext

1. Động cơ nghiên cứu

- Mặc dù SalsaNext đạt kết quả rất tốt trên SemanticKITTI, mô hình vẫn tồn tại một số hạn chế

Mất thông tin hình học khi chiếu Point Cloud sang Range View.

- Khó phân biệt các vật thể nhỏ như người đi bộ, xe đạp, cột điện.
- Chưa khai thác quan hệ không gian dài hạn giữa các vùng trong cảnh.
- Không tận dụng thông tin thời gian giữa các frame LiDAR liên tiếp.
- Chưa hỗ trợ trực tiếp Panoptic Segmentation.
- Hiệu suất giảm khi áp dụng sang các môi trường khác ngoài SemanticKITTI.

2. Cải tiến Backbone bằng Attention Mechanism

2.1 Hạn chế của Dilated Convolution

Trong SalsaNext, khả năng mở rộng receptive field được thực hiện bằng Residual Dilated Convolution Stack. Cách tiếp cận này cho phép tăng vùng quan sát mà không làm tăng quá nhiều số lượng tham số.

Tuy nhiên, dilated convolution vẫn là phép toán cục bộ.

Đối với dữ liệu LiDAR ngoài trời, các vật thể có cùng ngữ nghĩa thường nằm cách xa nhau trên ảnh Range View. Khi đó mạng khó học được mối quan hệ giữa các vùng không gian xa nhau.

Ví dụ:

- Hai xe hơi nằm ở hai làn đường khác nhau.
- Một người đi bộ nằm cạnh xe đạp.
- Một xe tải bị che khuất một phần bởi cây cối.

Các trường hợp trên đòi hỏi mô hình phải hiểu được ngữ cảnh toàn cục của cảnh quan.

2.2 Giải pháp đề xuất

Nghiên cứu đề xuất thay thế Context Module hiện tại bằng Transformer Attention Block.

Đầu vào của module là feature map sinh ra từ encoder.

Các đặc trưng sẽ được chuyển đổi thành ba ma trận:

- Query (Q)
- Key (K)
- Value (V)

Sau đó cơ chế Self-Attention được áp dụng để học mối liên hệ giữa mọi vị trí trên feature map.

Công thức Attention được biểu diễn như sau:

$$\text{Attention}(Q,K,V)=\text{Softmax}(\text{dkQKT})V$$

Thông qua cơ chế này, mô hình có thể xác định được những vùng đặc trưng có liên quan mặc dù chúng nằm rất xa nhau trên ảnh Range View.

2.3 Lợi ích

Việc tích hợp Attention mang lại các lợi ích:

- Tăng khả năng học ngữ cảnh toàn cục.
- Giảm nhầm lẫn giữa các lớp tương tự.
- Cải thiện phân đoạn đối tượng ở khoảng cách xa.
- Tăng khả năng xử lý các cảnh phức tạp có mật độ đối tượng lớn.

Đây cũng là hướng phát triển đang được áp dụng trong nhiều mô hình Range View hiện đại như RangeFormer.

3. Bổ sung Multi-scale Feature Fusion

3.1 Hạn chế của SalsaNext

Trong quá trình downsampling, các vật thể nhỏ như:

- Pedestrian
- Bicyclist
- Motorcycle
- Pole

thường chỉ chiếm vài pixel trên ảnh Range View.

Khi trải qua nhiều tầng encoder, các đặc trưng này dễ bị mất hoàn toàn.

Đây là nguyên nhân khiến độ chính xác trên các lớp nhỏ thường thấp hơn đáng kể so với xe hơi hoặc mặt đường.

3.2 Giải pháp đề xuất

Nghiên cứu đề xuất xây dựng Feature Pyramid Network (FPN).

Các feature map từ nhiều tầng encoder sẽ được kết hợp trước khi đưa vào decoder.

Cơ chế này cho phép:

- Giữ lại thông tin chi tiết từ tầng nông.
- Đồng thời khai thác đặc trưng ngữ nghĩa mạnh từ tầng sâu.

Feature fusion được mô tả như sau:

$$F_{\text{fusion}} = F_1 \oplus F_2 \oplus F_3 \oplus F_4$$

Trong đó:

- F_1, F_2, F_3, F_4 là các đặc trưng ở các mức độ khác nhau.
- $\oplus$ là phép hợp nhất đặc trưng.

3.3 Lợi ích

Việc sử dụng FPN giúp:

- Tăng khả năng nhận dạng vật thể nhỏ.
- Giảm mất mát thông tin biên.
- Cải thiện mIoU trên các lớp hiếm xuất hiện.

4. Bổ sung Attention Decoder

4.1 Hạn chế của Pixel Shuffle Decoder

SalsaNext sử dụng Pixel Shuffle để thay thế deconvolution nhằm giảm hiện tượng checkerboard artifact và tăng tốc độ xử lý.

Tuy nhiên decoder hiện tại chưa có cơ chế lựa chọn đặc trưng quan trọng.

Do đó:

- Biên vật thể thường chưa sắc nét.
- Các vùng nhiễu dễ bị phân loại sai.

4.2 Giải pháp đề xuất

Tích hợp CBAM (Convolutional Block Attention Module) vào decoder.

CBAM gồm hai thành phần:

Channel Attention

Xác định kênh đặc trưng quan trọng.

Spatial Attention

Xác định vị trí quan trọng trên feature map.

Hai cơ chế này giúp decoder tập trung vào vùng chứa vật thể thay vì vùng nền.

4.3 Kết quả mong đợi

- Biên vật thể rõ ràng hơn.
- Giảm nhầm lẫn giữa các lớp lân cận.
- Tăng độ chính xác của các đối tượng nhỏ.

5. Bổ sung Panoptic Segmentation Head

5.1 Động cơ

Semantic segmentation chỉ trả lời câu hỏi:

"Một điểm thuộc lớp nào?"

Ví dụ:

- Car
- Car
- Car

Tuy nhiên không thể biết có bao nhiêu xe xuất hiện trong cảnh.

Trong các hệ thống tự hành, việc phân biệt từng thực thể riêng biệt là rất quan trọng.

5.2 Giải pháp

Bổ sung nhánh Instance Segmentation tương tự Panoptic-PolarNet.

Backbone SalsaNext sẽ được chia thành hai nhánh:

Semantic Head

Dự đoán lớp ngữ nghĩa.

Instance Head

Dự đoán:

- Center Heatmap
- Offset Vector

Center Heatmap xác định tâm đối tượng.

Offset Vector biểu diễn hướng từ mỗi điểm tới tâm tương ứng.

5.3 Panoptic Fusion

Kết quả cuối cùng được tạo bằng cách kết hợp:

$\text{Panoptic} = \text{Semantic} + \text{Instance}$

Ví dụ:

Semantic	Instance
c	
Car	1
Car	2
Car	3

Kết quả:

- Car #1
- Car #2
- Car #3

5.4 Ý nghĩa

Panoptic Segmentation cho phép:

- Đếm số lượng đối tượng.
- Theo dõi từng đối tượng riêng biệt.
- Làm tiền đề cho bài toán Multi-Object Tracking.

6. Bổ sung Temporal Fusion

6.1 Hạn chế

SalsaNext xử lý từng frame LiDAR độc lập.

Điều này dẫn đến:

- Mất thông tin chuyển động.
- Dễ sai khi vật thể bị che khuất tạm thời.

6.2 Giải pháp

Sử dụng Temporal Feature Fusion.

Thay vì chỉ sử dụng frame hiện tại:

P_t

mô hình sẽ sử dụng:

(P_{t-2}, P_{t-1}, P_t)

Các đặc trưng được tổng hợp bằng Temporal Attention.

6.3 Lợi ích

Temporal Fusion giúp:

- Ổn định kết quả phân đoạn.
- Giảm hiện tượng nhấp nháy nhãn giữa các frame.
- Cải thiện nhận dạng vật thể bị che khuất.

Theo kinh nghiệm thực tế trong các hệ thống LiDAR, ngữ cảnh thời gian thường là yếu tố quan trọng để xử lý các trường hợp khó phân biệt như pedestrian và bicyclist.

7. Tích hợp Tracking

Sau khi thu được kết quả Panoptic Segmentation, nghiên cứu đề xuất bổ sung mô-đun Tracking.

Mỗi instance sẽ được gán:

- ID
- Vận tốc
- Quỹ đạo

Thông qua:

- Kalman Filter
- Hungarian Matching

Kết quả đầu ra:

Frame Instance

t Car #1

t+1 Car #1

t+2 Car #1

Hệ thống từ đó chuyển từ:

3D Panoptic Segmentation

thành

4D Panoptic Tracking.

8. Kết luận

Nghiên cứu đề xuất phiên bản Enhanced SalsaNext nhằm khắc phục những hạn chế của kiến trúc gốc thông qua bốn cải tiến chính gồm Transformer Attention, Multi-scale Feature Fusion, Panoptic Segmentation Head và Temporal Fusion. Các cải tiến này giúp mô hình không chỉ thực hiện semantic segmentation mà còn hỗ trợ nhận dạng từng thực thể riêng biệt và theo dõi đối tượng theo thời gian. Dự kiến mô hình mới sẽ nâng cao đáng kể độ chính xác trên các lớp vật thể nhỏ, cải thiện khả năng xử lý cảnh phức tạp và đáp ứng tốt hơn yêu cầu của các hệ thống UAV, robot tự hành và xe tự lái hiện đại.