HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO ĐỀ CƯƠNG HÀNG TUẦN

HỌC PHẦN: THỰC TẬP CƠ SỞ

ĐỀ TÀI : 3D PAGNOTIC SEGMANTATION CHO PHÂN TÍCH CẢNH TỪ DỮ LIỆU LiDAR

Giảng viên hướng dẫn	: TS. Kim Ngọc Bach
Mã sinh viên	: B23DCCN397
Tên sinh viên	: Nguyễn Nhật Huy
Lớp hành chính	: D23CQCN05-B
Nhóm thực tập	: 11

Hà Nội - 2026

I. Mục tiêu

- Tìm hiểu về Neural Network, CNN

- Tìm hiểu về Data SemanticKitti, 3D Semantic Segmantation

- Visualize data

- Tìm hiểu cấu trúc SalsaNext cho 3D Semantic Segmantation

II. Báo cáo

1. Neural Network

- Neural Network (Mạng nơ-ron nhân tạo) là một mô hình học máy được xây dựng dựa trên cách hoạt động của hệ thần kinh sinh học. Mô hình này gồm nhiều nơ-ron nhân tạo liên kết với nhau để học và biểu diễn các mối quan hệ phức tạp trong dữ liệu.

- Một neural network cơ bản thường bao gồm ba thành phần chính:

  - Input layer: nhận dữ liệu đầu vào
  - Hidden layers: các lớp ẩn thực hiện quá trình xử lý và trích xuất đặc trưng
  - Output layer: đưa ra kết quả dự đoán của mô hình

$$y = f(\sum_{i=1}^{n} w_i x_i + b)$$

- Trong đó:

  - xi: giá trị đầu vào
  - wi: trọng số của kết nối
  - b: bias
  - f: hàm kích hoạt (activation function)

- Trong quá trình huấn luyện, neural network sử dụng thuật toán lan truyền ngược (Backpropagation) kết hợp với gradient descent để cập nhật các trọng số của mạng, nhằm giảm sai số giữa kết quả dự đoán và nhãn thực tế.

2. Convolutional Neural Network

- Convolutional Neural Network (CNN) là một kiến trúc neural network được thiết kế đặc biệt để xử lý dữ liệu có cấu trúc dạng lưới như hình ảnh hoặc dữ liệu không gian.

- CNN có khả năng tự động học các đặc trưng không gian (spatial features) từ dữ liệu thông qua các phép convolution.

- Một mô hình CNN điển hình bao gồm các thành phần chính sau:

a. Convolutional Layer

- Convolution layer sử dụng các kernel (filter) để quét qua dữ liệu đầu vào nhằm trích xuất các đặc trưng quan trọng.

- Phép tích chập có thể được biểu diễn như sau:

$$\text{Feature Map} = \text{Input} * \text{Kernel}$$

b. Activation Function

- Sau mỗi convolution layer thường áp dụng hàm kích hoạt để tăng khả năng biểu diễn phi tuyến của mô hình.

- Hàm kích hoạt phổ biến nhất trong CNN là ReLU:

$$f(x) = \max(0,x)$$

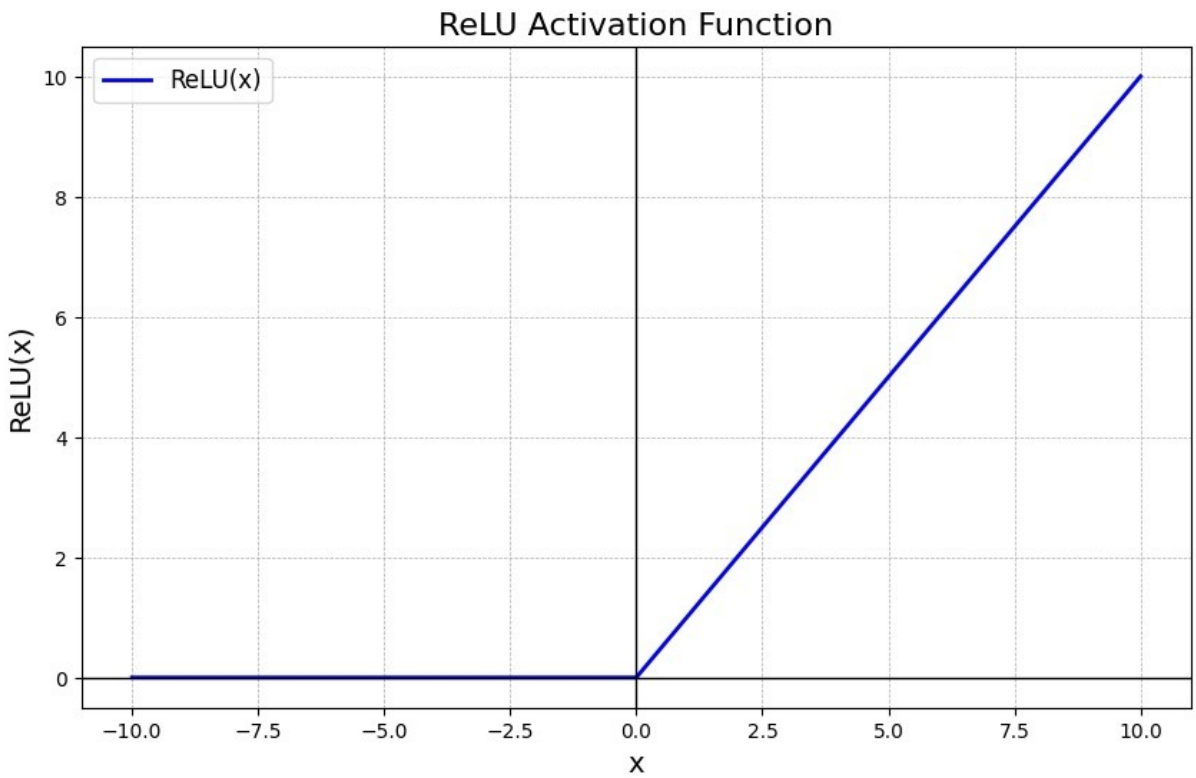

c. Pooling layer

- Pooling layer được sử dụng để giảm kích thước của feature map, giúp giảm chi phí tính toán và tránh overfitting.

- Hai loại pooling phổ biến:

  - Max Pooling: lấy giá trị lớn nhất trong vùng pooling
  - Average Pooling: lấy giá trị trung bình

d. Flatten Layer

- Trước khi đưa vào fully connected layer, các feature map được chuyển đổi thành vector một chiều thông qua bước flatten.
- Bước này giúp chuyển dữ liệu từ dạng không gian sang dạng vector để phục vụ cho quá trình phân loại.

e. Fully Connected Layer

- Sau khi trích xuất đặc trưng từ các econvolution layer, các feature map sẽ được flatten và đưa vào fully connected layer để thực hiện quá trình phân loại.

*** Ứng dụng của CNN**

- CNN được sử dụng rộng rãi trong các bài toán thị giác máy tính như:

  - Image classification
  - Object detection
  - Semantic segmentation
  - 3D point cloud segmentation

3. Data SemanticKitti

- SemanticKITTI là một bộ dữ liệu lớn được sử dụng phổ biến trong các nghiên cứu về 3D semantic segmentation cho LiDAR. Dataset này được xây dựng dựa trên dữ liệu LiDAR từ bộ dữ liệu KITTI Vision Benchmark Suite, trong đó các point cloud được gán nhãn ngữ nghĩa cho từng điểm.

- Dataset được thu thập từ cảm biến LiDAR gắn trên xe tự hành, ghi lại dữ liệu môi trường giao thông thực tế trong quá trình di chuyển.

*** Cấu trúc dữ liệu Point Cloud**

- Mỗi điểm trong point cloud có dạng:

$$(x, y, z, r)$$

- Trong đó:

- x: tọa độ theo trục trước – sau của xe
- y: tọa độ theo trục trái – phải
- z: tọa độ theo trục độ cao
- r: intensity (độ phản hồi của tia laser khi chạm vào bề mặt vật thể)

- Các điểm này tạo thành một 3D point cloud mô tả cấu trúc không gian của môi trường xung quanh xe.

*** Nhãn dữ liệu**

- Trong SemanticKITTI, mỗi điểm trong point cloud được gán một nhãn ngữ nghĩa. Các nhãn này đại diện cho các loại đối tượng khác nhau trong môi trường giao thông.

- Một số lớp phổ biến:

- road
- sidewalk
- building
- tree
- car
- truck
- bicycle
- pedestrian

- Tổng cộng dataset chứa hơn 20 lớp ngữ nghĩa, trong đó thường được nhóm lại thành:

- Stuff classes: các vùng không có ranh giới rõ ràng (road, vegetation, building)
- Thing classes: các đối tượng riêng biệt (car, person, bicycle)

- Tổng cộng dataset chứa hơn 20 lớp ngữ nghĩa, trong đó thường được nhóm lại thành:

- Stuff classes: các vùng không có ranh giới rõ ràng (road, vegetation, building)
- Thing classes: các đối tượng riêng biệt (car, person, bicycle)

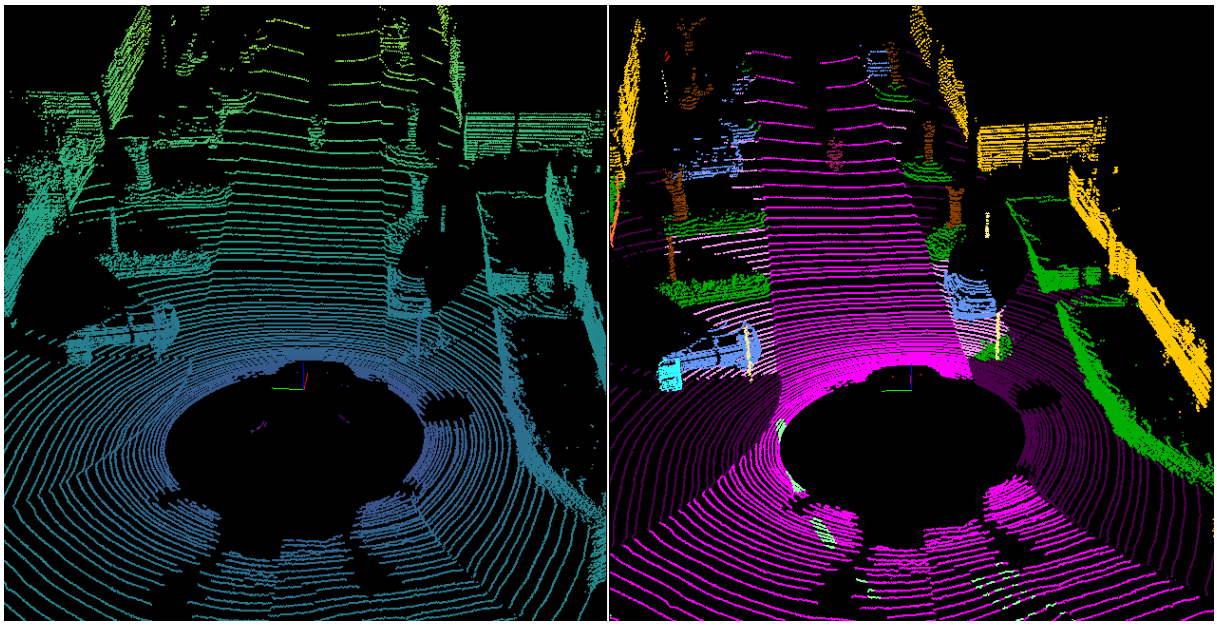

Hình 1: Dữ liệu point cloud trong SemanticKITTI trước và sau khi được gán nhãn semantic.

4. 3D SemantDic Segmantation

- 3D Semantic Segmentation là bài toán gán nhãn ngữ nghĩa cho từng điểm trong dữ liệu point cloud. Mục tiêu của bài toán là xác định loại đối tượng mà mỗi điểm trong không gian 3D thuộc về, ví dụ như road, car, pedestrian, building, tree. Đây là một nhiệm vụ quan trọng trong các hệ thống nhận thức môi trường của xe tự hành.

- Trong các dataset LiDAR như SemanticKITTI, mỗi điểm trong point cloud được biểu diễn bởi vector:

(x, y, z, r)

- Trong đó:

- x, y, z: tọa độ không gian của điểm
- r: intensity (độ phản xạ của tia laser)

- Mô hình 3D semantic segmentation sẽ nhận point cloud đầu vào và dự đoán nhãn cho từng điểm trong dữ liệu.

*** Các phương pháp tiếp cận**

- Do dữ liệu point cloud không có cấu trúc lưới cố định, nhiều phương pháp khác nhau đã được đề xuất để xử lý dữ liệu này.

a. Point - based method

- Phương pháp này xử lý trực tiếp trên tập điểm mà không cần chuyển đổi dữ liệu sang dạng khác

- Ưu điểm:

+ Giữ nguyên thông tin của point cloud(Không gian)

- Nhược điểm:

+ Tốn chi phí tính toán do số lượng điểm lớn

b. **Voxel - based Method**

- Point cloud được chuyển thành voxel grid (lưới 3D). Sau đó áp dụng các mạng CNN 3D để xử lý dữ liệu.

- Ưu điểm:

+ có thể áp dụng CNN truyền thống

- Nhược điểm:

+ tiêu tốn bộ nhớ

+ mất chi tiết khi voxel hóa

c. Range Image - Based Method

- Point cloud được chiếu lên ảnh 2D theo góc quét của LiDAR để tạo thành range image. Sau đó sử dụng CNN 2D để thực hiện segmentation.

- Một mô hình tiêu biểu của hướng này là: SalsaNext.

- Ưu điểm:

+ xử lý nhanh

+ tận dụng được các kiến trúc CNN mạnh

- Nhược điểm:

+ có thể mất thông tin hình học trong quá trình chiếu

5. SalsaNext Architecture

- Dữ liệu LiDAR thường được biểu diễn dưới dạng point cloud không có cấu trúc lưới cố định như ảnh 2D. Điều này khiến việc áp dụng trực tiếp các phương pháp CNN truyền thống trở nên khó khăn. Vì vậy nhiều phương pháp khác nhau đã được đề xuất để xử lý dữ liệu point cloud.

- SalsaNext là một mô hình deep learning được thiết kế cho bài toán 3D semantic segmentation trên dữ liệu LiDAR. Mô hình sử dụng phương pháp Range View (RV) để chiếu dữ liệu point cloud lên ảnh 2D, từ đó cho phép áp dụng các kiến trúc CNN 2D để trích xuất đặc trưng.

- Input của mạng là range image được tạo từ point cloud. Mỗi pixel trong ảnh tương ứng với một điểm trong dữ liệu LiDAR và chứa nhiều thông tin đặc trưng của điểm đó.

- Kiến trúc của SalsaNext được xây dựng dựa trên mô hình encoder–decoder, trong đó encoder có nhiệm vụ trích xuất đặc trưng và decoder có nhiệm vụ khôi phục độ phân giải để dự đoán nhãn semantic cho từng điểm.

5.1 Encoder – Decoder Architecture

*** Encoder**

- Encoder có nhiệm vụ trích xuất đặc trưng không gian từ dữ liệu đầu vào thông qua nhiều tầng convolution.

- Các đặc điểm chính của encoder:

+ sử dụng các residual blocks

+ áp dụng dilated convolution để mở rộng receptive field

+ thực hiện downsampling bằng average pooling

- Các tầng này giúp mô hình học được đặc trưng của các đối tượng trong môi trường như đường, xe, người đi bộ và các vật thể khác.

*** Decoder**

- Decoder có nhiệm vụ tăng độ phân giải của feature map để tạo ra bản đồ phân đoạn (segmentation map).

- Trong decoder:

  - các feature map được upsamplekết hợp với feature từ encoder thông qua skip connections

- Skip connections giúp giữ lại các thông tin chi tiết từ các tầng nông của mạng, từ đó cải thiện độ chính xác của segmentation.

5.2 Các thành phần quan trọng của SalsaNext

5.2.1 Contextual Module

- Trong bài toán semantic segmentation, thông tin ngữ cảnh (contextual information) đóng vai trò quan trọng để hiểu mối quan hệ giữa các đối tượng trong cảnh.

- SalsaNext sử dụng một contextual module ở đầu mạng để thu thập thông tin ngữ cảnh với receptive field lớn hơn.

- Module này sử dụng các convolution kernel như:

- 1×1 convolution
- 3×3 convolution

- Nhờ đó mô hình có thể khai thác thông tin toàn cục của cảnh đồng thời giữ lại chi tiết không gian.

5.2.2 Dilated Convolution

- Để trích xuất các đặc trưng không gian hiệu quả, SalsaNext sử dụng dilated convolution.

- Dilated convolution giúp:

- mở rộng receptive field
- giữ nguyên kích thước feature map
- không làm tăng đáng kể số lượng tham số

- Trong các block của encoder, nhiều convolution với dilation rate khác nhau được sử dụng để khai thác thông tin ở nhiều mức độ không gian.

- Kết quả của các convolution này được:

- concatenate
- đưa qua 1×1 convolution
- kết hợp với residual connection

- Điều này giúp mô hình học được các đặc trưng từ nhiều phạm vi không gian khác nhau.

5.2.3 Pixel-Shuffle Layer

- Trong phần decoder, SalsaNext sử dụng pixel-shuffle layer để thực hiện upsampling.

- Pixel-shuffle hoạt động bằng cách chuyển đổi thông tin từ chiều channel sang chiều không gian, từ đó tạo ra feature map có độ phân giải cao hơn.

- Cụ thể, pixel-shuffle biến đổi:

$(H \times W \times Cr^2) \rightarrow (Hr \times Wr \times C)$

Trong đó:

- H, W: chiều cao và chiều rộng
- C: số kênh
- r: tỉ lệ phóng to

Phương pháp này giúp:

- giảm chi phí tính toán
- giảm số lượng tham số so với transpose convolution.

5.2.4 Central Encoder-Decoder Dropout

- SalsaNext áp dụng dropout ở các tầng trung tâm của encoder và decoder thay vì toàn bộ mạng.

- Nguyên nhân là các tầng đầu của mạng thường học đặc trưng cơ bản như cạnh và góc. Nếu áp dụng dropout ở các tầng này có thể làm giảm khả năng học đặc trưng ban đầu.

- Do đó:

- không áp dụng dropout ở tầng đầu và tầng cuối
- dropout chỉ được sử dụng ở các tầng trung gian

- Cách tiếp cận này giúp cải thiện hiệu suất của mô hình.

5.3 Output của mô hình

- Sau khi decoder hoàn thành quá trình upsampling, một convolution 1×1 được sử dụng để đưa số kênh của feature map về số lượng lớp semantic.

- Sau đó, feature map được đưa qua softmax classifier để tính toán xác suất của từng lớp cho mỗi pixel.

- Kết quả cuối cùng là segmentation map, trong đó mỗi pixel tương ứng với một điểm trong point cloud và chứa nhãn semantic của điểm đó.

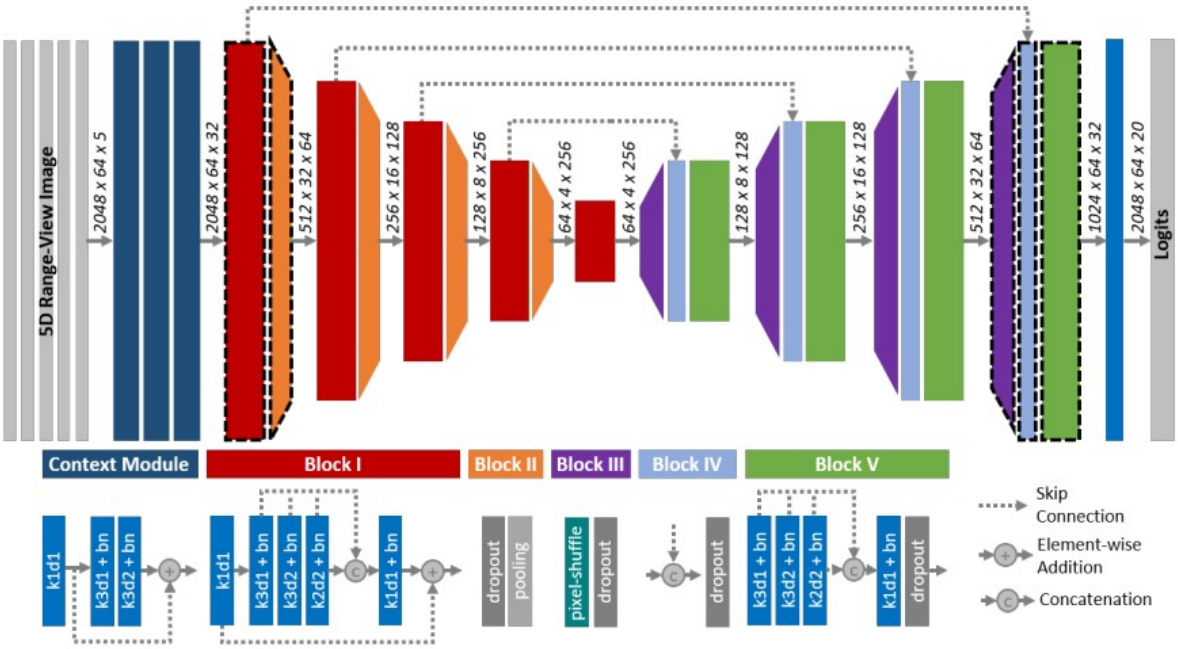

Hình 2: Cấu trúc SalsaNext

TÀI LIỆU THAM KHẢO

[1] Goodfellow, I., Bengio, Y., Courville, A., Deep Learning, MIT Press, 2016.

[2] LeCun, Y., Bengio, Y., Hinton, G., Deep Learning, Nature, 2015.

[3] Geiger, A., Lenz, P., Urtasun, R., Are We Ready for Autonomous Driving? The KITTI Vision Benchmark Suite, CVPR, 2012.

[4] Behley, J., et al., SemanticKITTI: A Dataset for Semantic Scene Understanding of LiDAR Sequences, ICCV, 2019.

[5] Qi, C. R., et al., PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation, CVPR, 2017.

[6] Mersch, B., et al., RangeNet++: Fast and Accurate LiDAR Semantic Segmentation, IROS, 2019.

[7] Cortinhal, T., Tzelepis, G., Aksoy, E., SalsaNext: Fast, Uncertainty-Aware Semantic Segmentation of LiDAR Point Clouds, ECCV, 2020.